T.C.

FIRAT ÜNİVERSİTESİ

MÜHENDİSLİK FAKÜLTESİ

Derin Öğrenme Tabanlı Yaklaşımla Kötü Huylu

Deri Kanserinin Dermatoskopik Görüntülerden Saptanması

ÖZET

Deri kanseri erken teşhis edilmezse ölümle sonuçlanan vakalara yol açabilir. Dermatoskopik (deri yüzeyi mikroskopisidir; benlerin ve pigmentli diğer lezyonların tanısında kullanılır.) görüntüler, deri kanserini erken teşhis etmek için en önemli veridir. Yapay zeka modellerini içeren bilgisayar destekli uygulamalar, dermatoskopik görüntülerden deri kanserini teşhis *etmek için uzmanlara yardım etmede faydalı bir araç olabilir. Özellikle, derin öğrenme tabanlı uygulamalar medikal görüntülerden hastalık tespit etmede popüler hale gelmiştir. Bu çalışmada, NasNet ,MobileNet ve EfficientNet modellerini içeren bir derin öğrenme tabanlı yaklaşım, dermatoskopik görüntülerden kötü huylu deri kanserini teşhis etmek için kullanılmıştır. Önceden eğitilmiş modeller ile katmanlardaki değerler kullanılarak öznitelikler çıkarılmıştır. Önerilen yöntemle %85.64, %94 ve %75.18 sınıflandırma doğrulukları elde edilmiştir. Bu çalışmada, eğitim sürecinde düşük hesaplama maliyeti elde edilmiştir. Gelecek

çalışmalarda birden çok derin öğrenme modelleri ile elde edilen özniteliklerle sınıflandırma performansı daha da artırılmaya çalışılacaktır.

Anahtar kelimeler: Kötü Huylu Deri Kanseri, MobileNetV2, NASNet , EfficientNet ,Öznitelik Seçme, Sınıflandırma.

1.GİRİŞ

1.1 Deri Kanseri

Deri kanseri, dünya genelinde en sık görülen kanser türlerinden biri olup, erken teşhis edilmediği durumlarda ölümcül sonuçlara yol açabilmektedir. Melanom gibi agresif türler, hızlı yayılma potansiyeline sahip olması nedeniyle ciddi bir halk sağlığı tehdidi oluşturmaktadır. Hastalığın erken aşamalarda teşhis edilmesi, yaşam kalitesini artırmak ve tedavi süreçlerini daha etkili hale getirmek için kritik öneme sahiptir. Bu süreçte dermatoskopik görüntüler, deri yüzeyindeki lezyonların detaylı incelenmesi ve kanser teşhisi için kullanılan en önemli tanı araçları arasında yer alır. Ancak, bu görüntülerin doğru bir şekilde analiz edilmesi genellikle zaman alıcıdır ve uzmanların bilgi ve deneyimlerine bağlı olarak değişkenlik gösterebilir.

Son yıllarda, yapay zeka (YZ) ve özellikle derin öğrenme tabanlı yaklaşımlar, tıbbi görüntü analizinde devrim niteliğinde yenilikler getirmiştir. Bu teknolojiler, insan hatasını azaltma, analiz süreçlerini hızlandırma ve doğruluk oranlarını artırma potansiyeli ile ön plana çıkmaktadır. Derin öğrenme tabanlı yöntemler, deri kanseri gibi karmaşık ve görsel özelliklerin belirleyici olduğu hastalıkların teşhisinde umut vaat eden araçlar haline gelmiştir.

Bu çalışmada, farklı derin öğrenme modelleri karşılaştırılarak, dermatoskopik görüntülerden kötü huylu deri kanserinin tespiti amaçlanmıştır. Geleneksel yöntemlerle karşılaştırıldığında, önerilen yaklaşım düşük hesaplama maliyetleri ve yüksek doğruluk oranlarıyla dikkat çekmektedir.

1.2 İlgili Çalışmalar

Cilt lezyonlarının otomatik segmentasyonu ve sınıflandırılması, literatürde kapsamlı bir şekilde ele alınmıştır [1],[2]. Geleneksel yöntemler arasında kümeleme, eşikleme, bölge büyütme ve aktif kontur modelleri gibi teknikler bulunmaktadır [3],[4]. Sınıflandırma yöntemleri ise lezyonların renk, doku, sınır düzensizliği ve asimetri gibi el ile tasarlanmış özelliklerini

çıkararak bu özellikleri sınıflandırıcılarla analiz etmeye odaklanır. Bu sınıflandırıcılar arasında K-en yakın komşu [5], geri yayılım sinir ağı [6], destek vektör makineleri [7], doğrusal sınıflandırıcı [8], lojistik regresyon [9] gibi yöntemler yer alır. Ancak, el ile tasarlanmış özelliklere dayalı bu yaklaşımlar, doğruluk açısından sınırlamalar içermektedir.

Son yıllarda, derin evrişimli sinir ağları (DCNN'ler), hem özellik çıkarımı hem de sınıflandırmayı bir arada öğrenerek el ile özellik çıkarımı ihtiyacını ortadan kaldırmıştır [1], [10], [11], [12], [2], [13], [14]. Özellikle cilt lezyonu segmentasyonu için çeşitli DCNN tabanlı yöntemler önerilmiştir. Örneğin, Yuan ve arkadaşları [1], Jaccard mesafe kaybı kullanılarak optimize edilen 19 katmanlı derin bir FCN geliştirdi. Li ve arkadaşları [10], artık öğrenmeye dayalı yeni bir yoğun dekonvolüsyonel ağ sundu. Mirikharaji ve Hamarneh [11], her segmentasyon sonucunda küresel bir yapı sağlamak için yıldız şekli önceliğini kayıp fonksiyonuna kodlamayı önerdi. Sarker ve arkadaşları [15], elde edilen lezyon sınırlarının doğruluğunu artırmak için sağlam bir derin kodlayıcı-kod çözücü ağ sundu.

Bazı sistemler, pigment ağı [16], [17], [18], düzensiz çizgiler [19], granüler yapılar [20], regresyon yapıları [19], mavi-beyaz örtü [21] ve lekeler [22] gibi dermoskopik yapıları tespit ederek dermatologların performansını taklit etmeye çalışmaktadır. Literatürde 7-nokta kontrol listesi yöntemini taklit eden CAD sistemleri de bulunabilir [23]. Çoğu melanom tespiti sistemi, desen tanıma yaklaşımını takip etmekte ve genellikle üç adım içerir: lezyon segmentasyonu, özellik çıkarımı ve sınıflandırma. Bu sistemler genellikle ABCD kuralından ilham alır [24]. En yaygın kullanılan özellikler arasında şekil (ör. kompaktlık), renk (ör. ortalama renk) ve doku (ör. gri düzey eş-oluşum matrisi) yer alır [25].

Farklı çalışmalar, bu özellik setleriyle değişik sınıflandırıcılar kullanarak etkili sonuçlar elde etmiştir. Örneğin, Ganster ve ark. [5], k-En Yakın Komşu (k-NN) sınıflandırıcısı kullanarak %87 hassasiyet (SE) ve %92 özgüllük (SP) elde etmiştir. Rubegni ve ark. [26], Yapay Sinir Ağı (ANN) kullanarak %96 SE ve %93 SP sağlamıştır. Celebi ve ark. [25], Destek Vektör Makineleri (SVM) kullanarak %93 SE ve %92 SP elde etmiştir. Iyatomi ve ark. [27] %86 SE ve SP değerleriyle benzer sonuçlar almıştır.

Bu çalışmalar, melanom tespiti için şekil, renk ve doku özelliklerinin eşit derecede önemli olduğunu varsayar. Diğer çalışmalar ise tek bir özellik sınıfını kullanmaktadır [28], [29], [30], [31], [32]. Örneğin, Seidenari ve ark. [29], renk dağılımını kullanarak %86 doğruluk elde etmiştir. Gri düzey eş-oluşum matrisi gibi doku tanımlayıcıları, doku bilgisiyle yapılan çalışmalarda %92 doğruluk sağlamıştır [32]. Ancak, farklı veri setleri ve deneysel koşullar nedeniyle bu sonuçlar karşılaştırılamaz.

1.3 Mevcut Yöntemin Eksiklikleri

Geleneksel yöntemler, deri lezyonlarının renk, doku, şekil ve sınır düzensizliği gibi özelliklerini manuel olarak çıkarır ve bu özelliklere dayalı sınıflandırma yapar. Ancak bu süreç; Uzman müdahalesine yüksek derecede bağımlıdır bu da analiz süreçlerinde hata oranını artırabilir, özelliklerin doğru ve eksiksiz bir şekilde çıkarılamaması durumunda sınıflandırma performansı olumsuz etkilenir ve karmaşık görsel yapıları yeterince temsil edemediği için düşük doğruluk oranlarına neden olabilir. Geleneksel segmentasyon ve analiz süreçlerinde, uzmanların yorumlarına dayalı olarak tekrarlanabilirlik ve tutarlılık sınırlı kalmaktadır. Bu durum, teşhis sonuçlarının standardizasyonunu zorlaştırmaktadır. Bu yaklaşımlar genellikle tek bir veri kümesine özel olarak optimize edilmekte, farklı veri setleri üzerinde performans düşüşü yaşamaktadır. Modellerin genelleme yeteneği sınırlıdır. Bazı literatür çalışmalarında kullanılan yöntemler, karmaşık algoritmalar ve yüksek hesaplama gereksinimleri nedeniyle pratik uygulamalarda kullanımı zorlaştırmaktadır.

1.4 Önerilen Yöntemin Üstünlükleri

Önerilen yaklaşımda, NASNet, MobileNet ve EfficientNet gibi önceden eğitilmiş derin öğrenme modelleri kullanılmıştır. Bu modeller; manuel özellik çıkarma ihtiyacını ortadan kaldırarak otomatik ve kapsamlı bir şekilde özellik çıkarımı sağlar, karmaşık görsel yapıların daha iyi temsil edilmesini mümkün kılar. Modeller sırasıyla %85.64, %94 ve %75.18 doğruluk oranlarıyla sınıflandırma performansında önemli bir artış sağlamıştır. Önerilen yöntemde kullanılan derin öğrenme modelleri, eğitim sürecinde düşük hesaplama maliyetleri ile öne çıkmaktadır. Bu durum, yöntemlerin pratik uygulamalarda kullanılabilirliğini artırmaktadır. Birden fazla derin öğrenme modelinin değerlendirilmesi, modellerin göreceli performanslarını anlamayı mümkün kılarak, en etkili çözümün seçilmesine olanak tanımıştır. Çalışma, birden fazla modelden elde edilen özelliklerin birleştirilmesi ve farklı sınıflandırıcılarla optimize edilmesiyle performansın daha da artırılabileceğini önermektedir. Bu durum, literatürdeki boşlukların doldurulmasına yönelik yeni fırsatlar sunmaktadır.

2.YÖNTEM

2.1 Veri Setinin Oluşturulması

Kaynak olarak hazır bir veri seti kullanıldı ve bunun üzerinde birtakım değişiklikler gerçekleştirildi. Herhangi bir değişiklik uygulamadan önceki veri setinin görünümü Şekil 1'de verilmiştir.

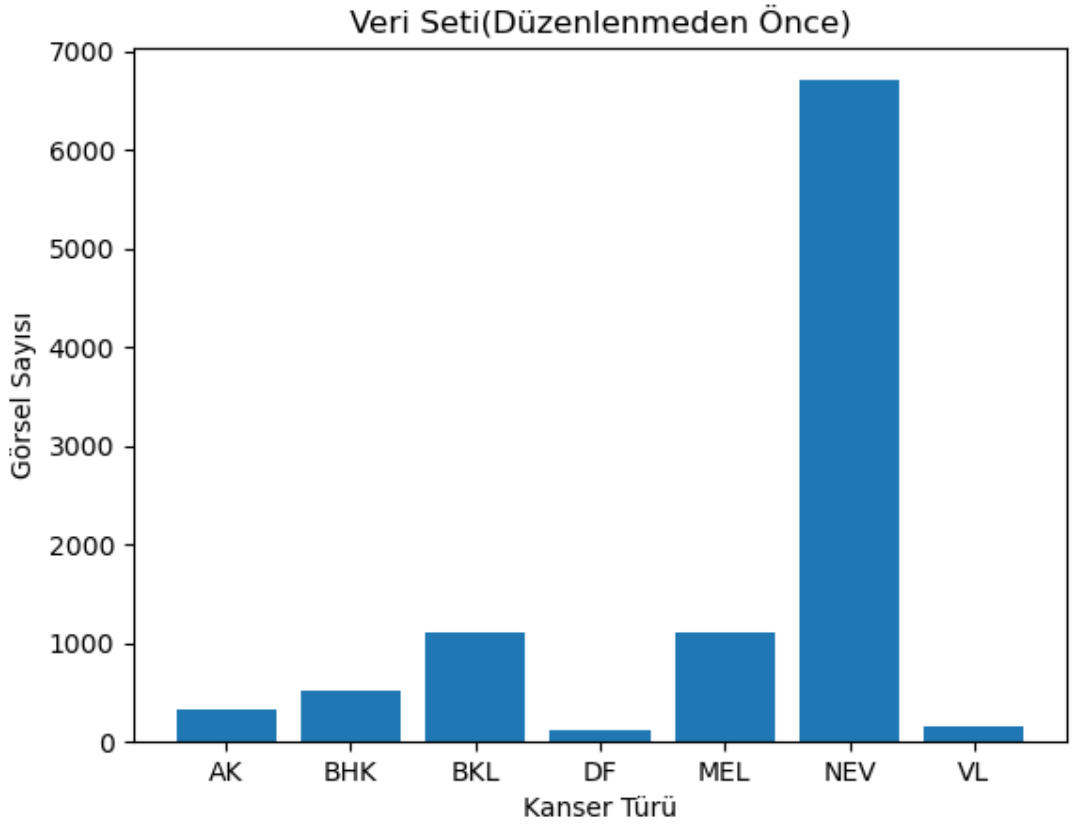

Şekil 1

Bu veri setinde sınıflar arasında homojen olmayan bir dağılım söz konusudur. Şayet herhangi bir düzenleme gerçekleştirilmeden kullanılırsa kimi sınıfların daha baskın öğrenilmesine yol açabilir. Veri setini düzenlemek için: NEV(Nevüs) isimli sınıftan rastegele olarak 1500 adet görsel seçme ve örnek sayısı 1000'in altında olan sınıflar için(Aktinik Keratoz, Bazal Hücreli Karsinom, Dermatofibroma, Vasküler Lezyonlar) birtakım görsel artırma işlemleri gerçekleştirilmiş olup, hali hazırda 1000-1500 aralığında örnek sayısı bulunan sınıflar için(Benign Keratoz Lezyonu, Melanom) herhangi bir işlem uygulanmamıştır. Sözü geçen işlemler uygulandıktan sonra veri setinin büründüğü görünüm Şekil 2'de gösterilmiştir.

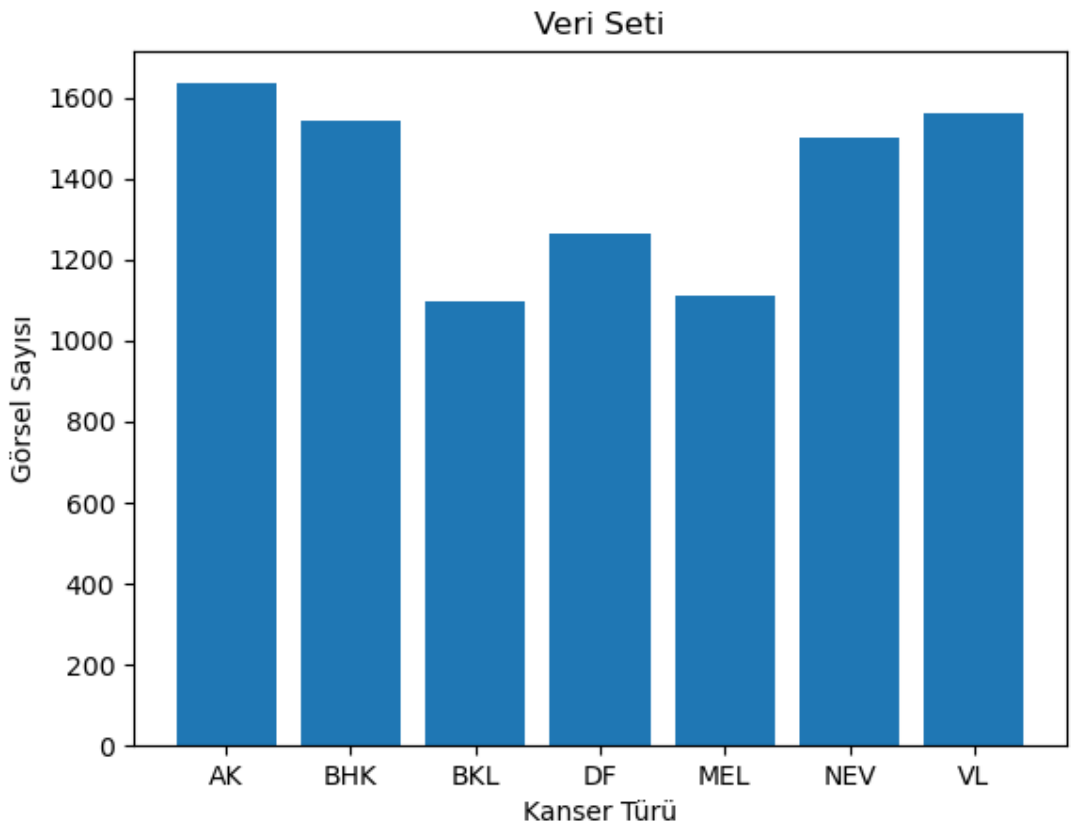

Şekil 2

2.2 Özelliklerin Çıkarılması Ve Seçilmesi

Özellik haritalarının elde edilmesi için MobileNetV2 modelinin “AvgPool 7x7” isimli katmanının girişi kullanıldı. Modelin katman mimarisi Tablo - 1’de verilmiştir.

Tablo 1 - MobileNetV2'in katman mimarisi:

Input Size	Operator	Expansion Factor (t)	Output Channels (c)	Number of Repeats (n)	Stride (s)
224x224x3	Conv2D	-	32	1	2
112x112x32	Bottleneck	1	16	1	1
112x112x16	Bottleneck	6	24	2	2
56x56x24	Bottleneck	6	32	3	2
28x28x32	Bottleneck	6	64	4	2
14x14x64	Bottleneck	6	96	3	1
14x14x96	Bottleneck	6	160	3	2
7x7x160	Bottleneck	6	320	1	1
7x7x320	Conv2D	-	1280	1	1
7x7x1280	AvgPool 7x7	-	-	1	-
1x1x1280	Conv2D	-	k (number of classes)	1	-

Elde edilen özelliklerin boyutu(her bir görsel için): (7,7,1280) olup, her bir görsel için 7x7'lik matrislerden oluşan 1280 tane kanalı niteler.[1]

Modelden çıkartılan özelliklerin seçimi için standart sapma yöntemi kullanıldı. Bu yöntem: özellik haritalarını niteleyen her bir kanalın, ayrı ayrı standart sapmalarının hesaplanması sonucunda en yüksek sapmaya sahip olanların seçilmesi işlemidir. Bu çalışmada, derin öğrenme modeli olarak MobilenetV2 kullanılmıştır. Modelin "AvgPool 7x7" katmanının girişinden elde edilen özellik haritaları, veri setinin yüksek boyutlu temsilini içermektedir. Özellik seçimi sürecini birkaç adım şeklinde özetlemek gerekirse: özellik haritalarının elde edilmesi için MobilenetV2 modelinin önceden eğitilmiş ağı kullanılarak giriş verilerinin işlenmesi, elde edilen her bir özellik haritası için standart sapma değerleri hesaplanmıştır. Standart sapma, verinin çeşitliliğini ve dağılımını belirlemek için kullanılmıştır. Yüksek standart sapma değerine sahip özellikler, modelin performansına en çok katkıda bulunan özellikler olarak seçilmiştir. Sapma değerlerine dayanarak, en yüksek standart sapma değerine sahip özellikler seçilmiştir. Bu işlem, modelin eğitim süresini kısaltmak ve doğruluğunu artırmak amacıyla yapılmıştır.

2.3 Aşırı Öğrenme Tespiti

Özellik seçimi sonrası modelin performansı değerlendirilmiş ve aşırı öğrenme belirtileri tespit edilmiştir. Aşırı öğrenme, modelin eğitim verileri üzerinde yüksek performans gösterirken, test verileri üzerinde düşük performans göstermesi durumudur. Bu durumu tespit etmek için modelin eğitim süreci boyunca epoch sayısına göre eğitim ve test verileri için doğruluk (accuracy) ve kayıp (loss) değerleri kaydedilmiş, bu değerler grafiklerle görselleştirilmiştir. Bu grafikler(Şekil 3), modelin aşırı öğrenme eğilimlerini açıkça ortaya koymaktadır. Özellik seçimi işlemi uygulandıktan sonra modelde aşırı öğrenme gözlendi. Bu nedenle özellik seçimi yöntemini kullanmayarak model eğitiminin tamamlanmasına karar verildi.

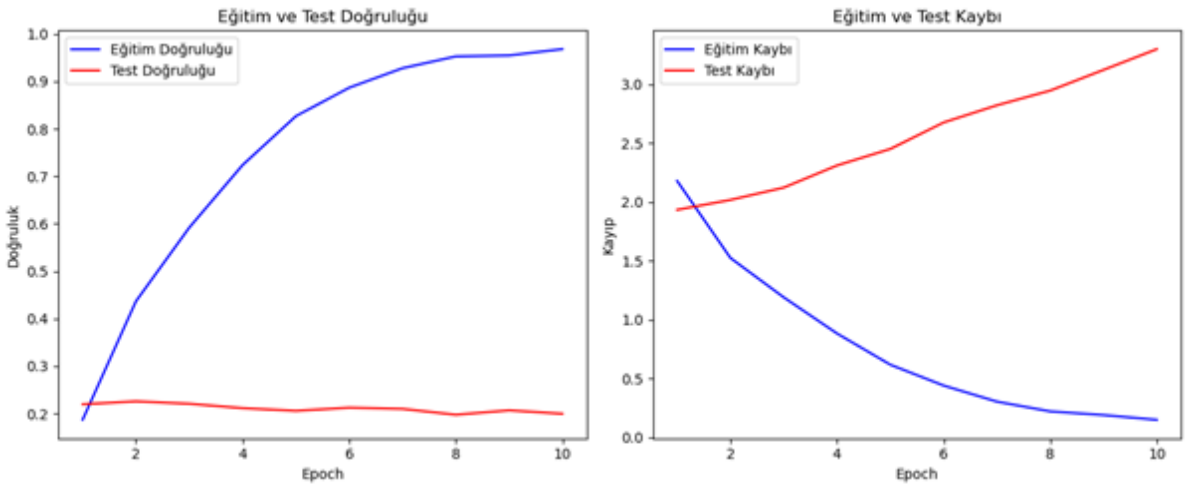

Şekil 3

2.4 EfficientNet

Deri kanseri sınıflandırması için 7 farklı deri lezyon tipini (Actinic Keratosis, Basal Cell Carcinoma, Benign Keratosis Lesion, Melanoma, Nevus, Dermatofibroma, Vascular Lesions) içeren bir veri seti kullanılmıştır. Veri setine döndürme, kaydırma, şekil bozulması ve yatay çevirme gibi veri artırma teknikleri uygulanarak çeşitlilik artırılmıştır. EfficientNetB0, ImageNet veri setinde önceden eğitilmiş bir model olarak transfer öğrenme yöntemiyle uyarlanmıştır. Modelin kaman mimarisi, Şekil 4'te gösterilmiştir. Modelin son katmanları, GlobalAveragePooling2D, Dropout ve yoğun (dense) katmanlarla özelleştirilmiştir. GlobalAveragePooling2D katmanı, EfficientNetB0 modelinden elde edilen özellik haritalarını sıkıştırarak daha düşük boyutlu bir temsil elde etmiştir. Dropout katmanı, aşırı öğrenmeyi önlemek amacıyla modelin bazı bağlantılarını rastgele devre dışı bırakmıştır. Yoğun katmanlar ise sınıflandırma görevine uygun şekilde tasarlanmıştır. Transfer öğrenme sırasında temel EfficientNetB0 katmanları dondurulmuş ve yalnızca eklenen katmanlar

eğitilmiştir. Eğitim sürecinde, erken durdurma (EarlyStopping) tekniği ile doğrulama kaybı iyileşme göstermediğinde eğitim sona erdirilmiştir. İnce ayar sürecinde, EfficientNetB0'ın temel katmanları çözülerek yeniden eğitilmiş ve düşük bir öğrenme oranı kullanılmıştır. Bu süreç, modelin erken aşamalarda öğrendiği genel özelliklerin daha spesifik sınıflandırma görevine uyarlanmasını sağlamıştır.

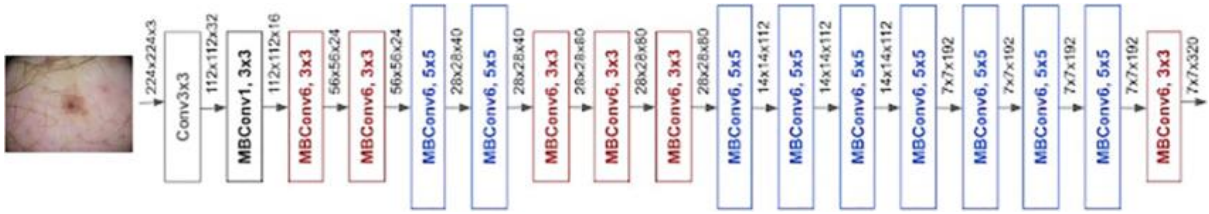

Şekil 4 – EfficientNet'in Katman Mimarisi

3. DEĞERLENDİRME SONUÇLARI

Bu çalışmada, dermatoskopik görüntülerden kötü huylu deri kanserini saptamak için çeşitli derin öğrenme modelleri içeren bir yaklaşım kullanılmıştır. Ayrıca önerilen yöntemin başarımını artırmak için transfer öğrenme kullanılmıştır. Öznitelik seçimi kullanılmadan önerilen yöntemin sınıflandırma doğruluğu %75.18 olmuştur. Ayrıca aynı veri setini kanserli hücre tespiti için en iyi model belirlenmek istenmiştir. Bununla birlikte diğer derin öğrenme tabanlı yaklaşımlar kullanılarak sınıflandırma doğruluğu artırılacağı düşünülmektedir. Bu çalışmada, sıfırdan eğitimli bir derin öğrenme modeli kullanılmadığı için eğitim sürecinde düşük hesaplama maliyeti elde edilmiştir. Bu durum da öğrenilebilir parametrelerin optimizasyon süresini azaltmıştır. Ayrıca öznitelik seçme algoritmalarıyla öğrenilebilir parametre sayısı daha da azaltılmıştır. Dahası daha az parametre ile daha yüksek bir başarım elde edilmiştir. Önerilen bu yöntemin uzmanlara karar vermede yardımcı bir araç olarak kullanılması düşünülmektedir.

NASNet Sonuçları:

NASNet, EfficientNet ve MobileNet v2 modellerinin karşılaştırıldığı bir eğitim sürecinde, öncelikle NASNet modeli kullanılarak iki aşamalı bir eğitim gerçekleştirilmiştir. İlk eğitiminde %69'luk bir başarı(Şekil 5) elde eden NASNet, aynı veri setiyle iki kez eğitilmiş ve optimize edilmiştir. Bu süreç sonucunda model, %71 doğruluk oranına ulaşmayı başarmıştır(Şekil 6). İki kez eğitim yapılması, modelin öğrenme kapasitesini artırarak daha tutarlı bir performans elde etmesine olanak tanımıştır. Modelin tahmin performansını nitelemek amacıyla Şekil 7'de, modele ait bir karmaşıklık matrisi verilmiştir. Eğitim süreci sonrasında NASNet'in doğruluk oranı, diğer modeller olan EfficientNet ve MobileNet v2 ile kıyaslanmış ve NASNet'in optimize edilmiş mimarisi sayesinde görüntü sınıflandırma görevlerinde güçlü bir performans sergilediği gözlemlenmiştir.

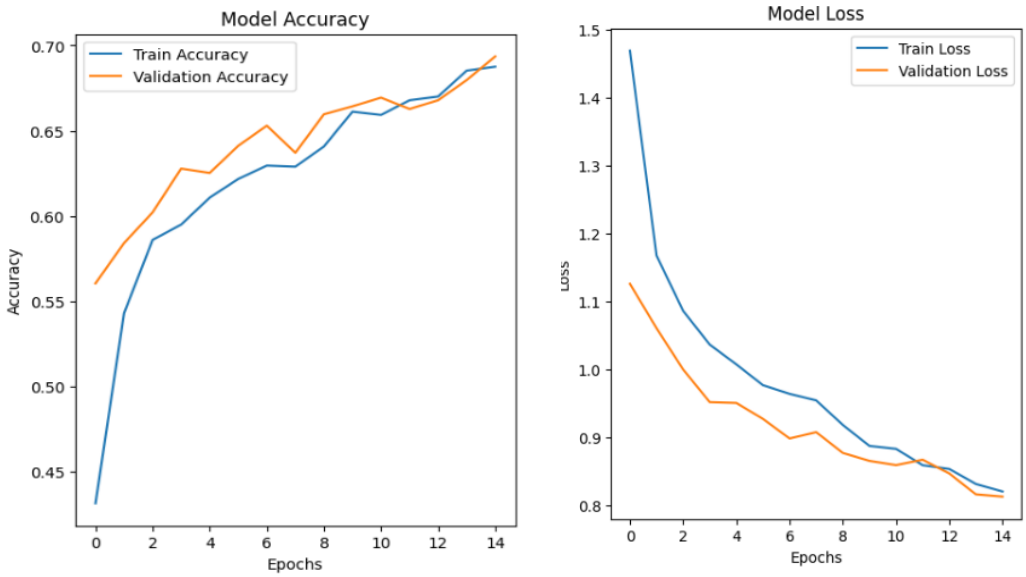

Şekil 5 – İlk eğitim sonucunda eğitim doğruluk-kayıp değerleri

Şekil 6 – İkinci eğitim sonucunda eğitim doğruluk-kayıp değerleri

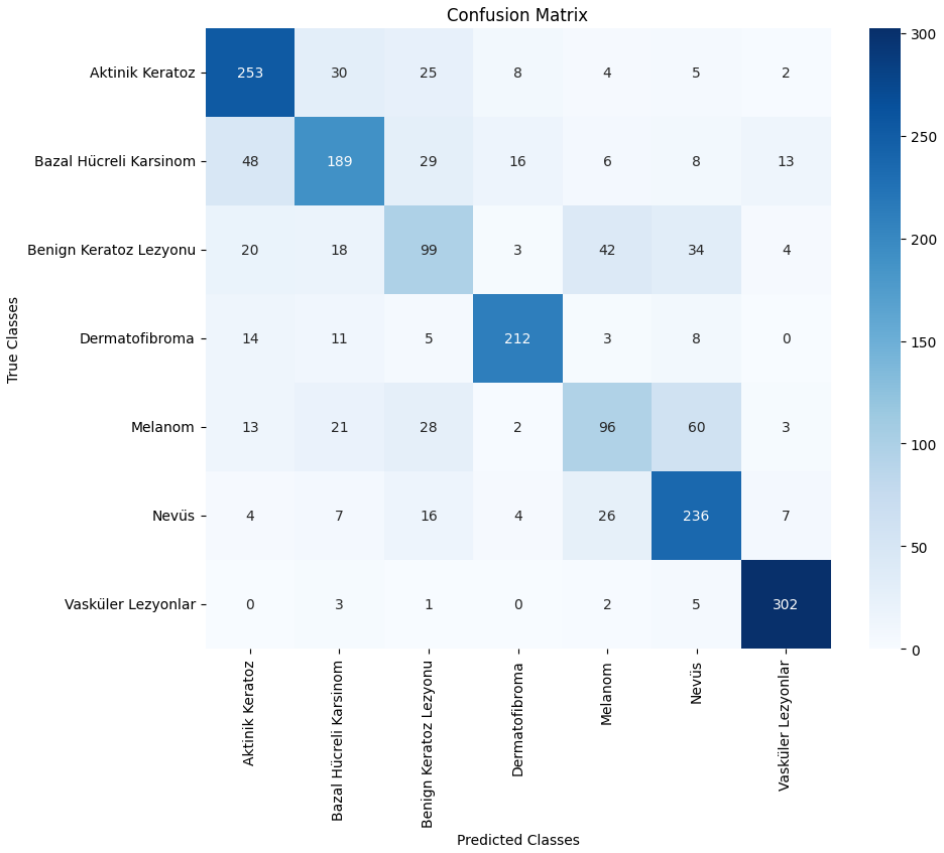

Şekil 7 – Karmaşıklık matrisi

MobileNet Sonuçları:

MobileNet, mobil cihazlar ve düşük güçlü sistemler için tasarlanmış hafif ve hızlı bir derin öğrenme modelidir. Klasik konvolüsyonlar yerine, işlemleri daha verimli hale getiren derinlik ayrılmalı konvolüsyonlar kullanır. Bu sayede hem az yer kaplar hem de gerçek zamanlı uygulamalarda yüksek performans sağlar.

Sonuçlandırma için yapılan karmaşıklık matrisi ve sınıflandırma raporu ilk olarak veri dengesizliğinden dolayı aşırı öğrenme ve öğrenme skorlarında dengesizlik gibi sıkıntılardan dolayı istenilen sonucu vermemiştir. Daha sonra veri seti düzenlenerek bu problem ortadan kaldırılmıştır. Veri seti dengesizken yapılan sınıflandırma raporunda doğruluk oranı %72.22'dir(Şekil 8). Veri seti düzenleme işlemi ardından bu oran %13.42 iyileşerek 85.64 değerlerine ulaşmıştır(Şekil 9). Modelin test verilerinden seçilen rastgele 10 tanesi üzerine gerçekleştirmiş olduğu tahminler Şekil 10'da gösterilmiştir.

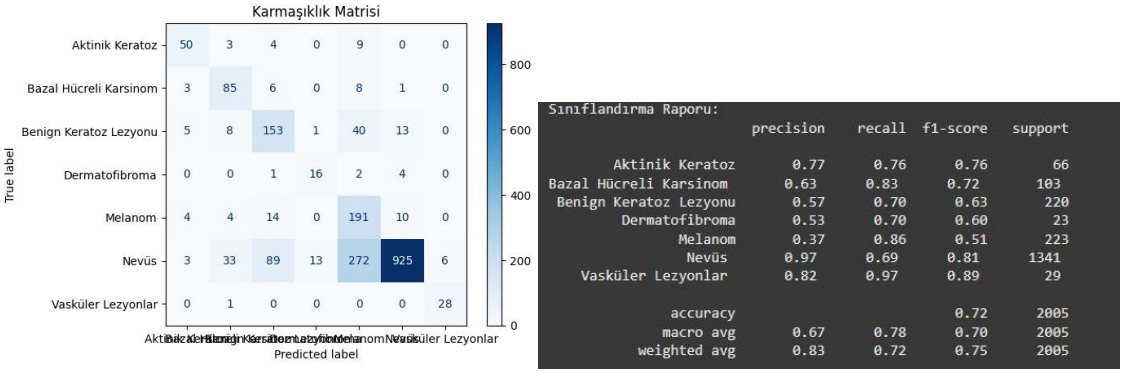

Şekil 8 – Dengesiz Veri Seti Sonuçları

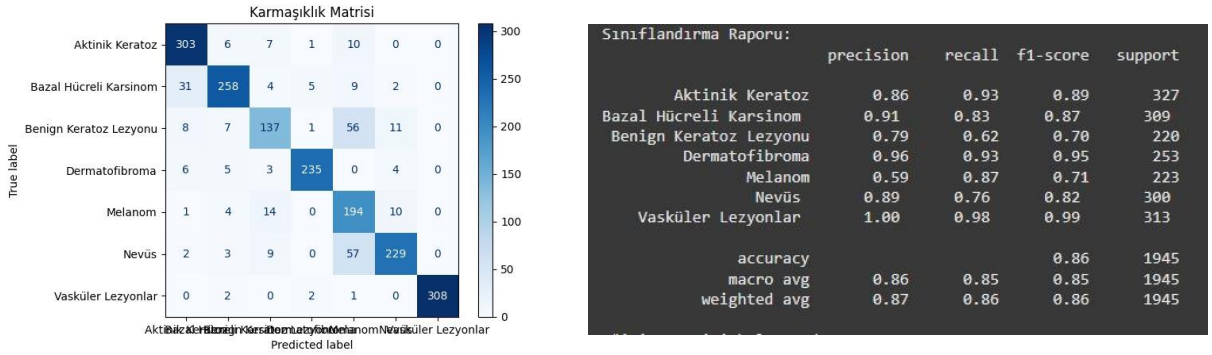

Şekil 9- Dengeli Veri Seti Sonuçları

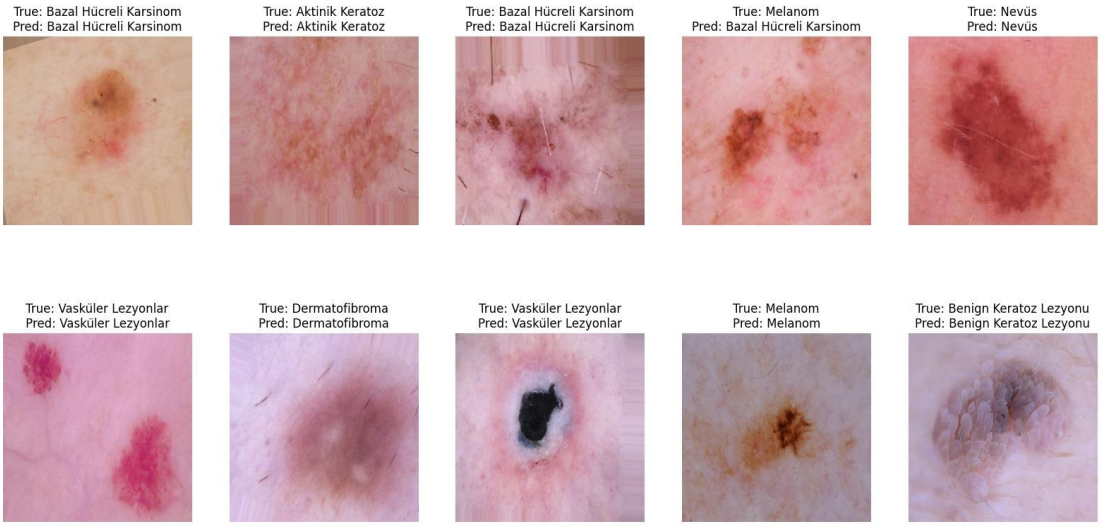

Şekil 10 – Test Verisi Üzerinde Modelin Tahmini Ve Gerçek Sınıfları

MobilNetV2-İkinci Kez Eğitim Sonuçları:

MobileNet v2, dar bant genişliği ve düşük işlem gücü gereksinimi ile dikkat çeken bir modeldir ve özellikle mobil uygulamalar için yaygın olarak tercih edilmektedir. Eğitim süreci MobileNet v2 ile devam ettiğinde, model %94 doğruluk oranına ulaşarak etkileyici bir performans sergilemiştir(Şekil 11). MobileNet v2'nin hızlı eğitilebilirliği ve optimize edilmiş yapısı, bu yüksek doğruluk oranını kısa sürede elde etmeyi mümkün kılmıştır. Bu sonuç, MobileNet v2'nin hafifliği ve yüksek doğruluk oranını bir arada sunarak, sadece mobil cihazlarda değil, geniş bir kullanım alanında güçlü bir seçenek olduğunu göstermiştir.

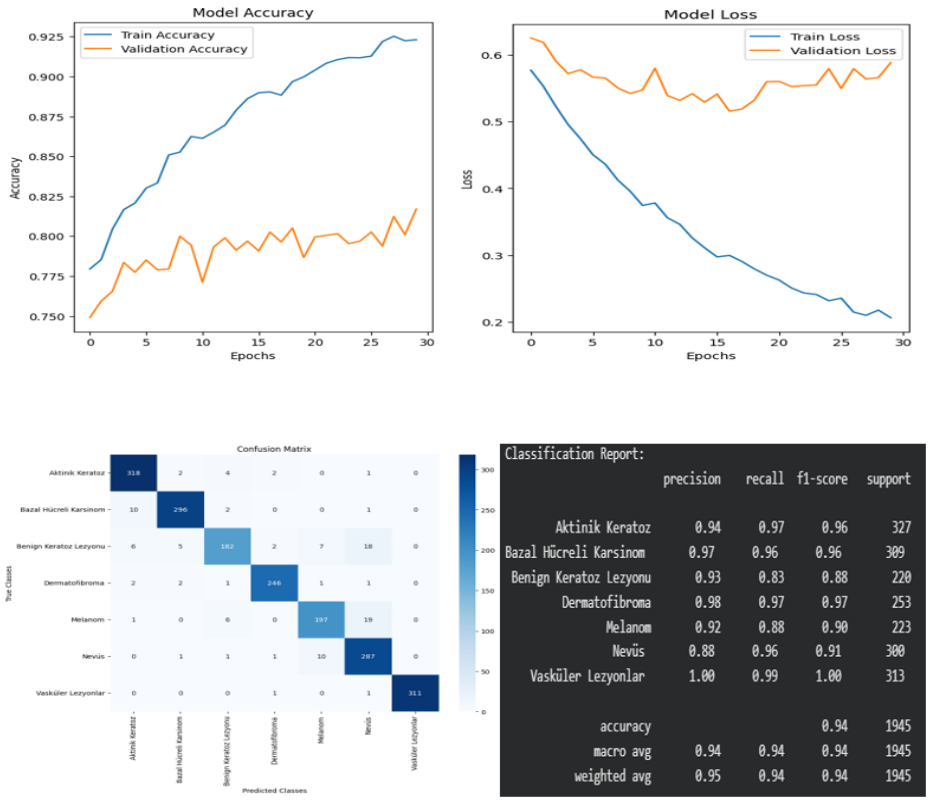

Şekil 11 – Modelin Başarımını Gösteren Şekiller

EfficientNet Sonuçları:

EfficientNet tabanlı model, deri kanseri sınıflandırmasında başarılı bir performans göstermiştir. Modelin eğitim sürecinde doğruluk ve kayıp metrikleri izlenerek erken durdurma tekniği ile aşırı öğrenmenin önüne geçilmiştir. Konfizyon matrisi ve sınıflandırma raporları, modelin sınıf bazında dengeli bir performansa ulaştığını göstermiştir. Özellikle, hassas sınıflarda gözlemlenen doğruluk oranları, modelin dermatolojik uygulamalarda kullanılabilir potansiyele sahip olduğunu ortaya koymuştur. Ayrıca, ince ayar süreci, temel modelin

öğrenme kapasitesini daha iyi kullanarak performansı daha da artırmıştır. Gerçekleştirilen ayarlamadan önce ve sonrası için doğruluk-kayıp değerleri sırasıyla Şekil 12 ve Şekil 13'te verilmiştir. Modelin tahmin yeteneği, bir karmaşıklık matrisi ile Şekil 14'te gösterilmiştir.

Bu çalışma, EfficientNet mimarilerinin transfer öğrenme yöntemleri ile sağlık verisi analitiğinde güçlü bir araç olabileceğini vurgulamaktadır. Gelecekte, daha büyük ve çeşitli veri setleri ile modelin genelleşme yeteneğinin artırılması, farklı demografik özelliklere sahip popülasyonlar için daha kapsayıcı bir performans sunabilir. Ek olarak, gerçek zamanlı uygulamalarda modelin entegrasyonu, tanı süreçlerini hızlandırabilir ve sağlık hizmetlerinin erişilebilirliğini artırabilir.

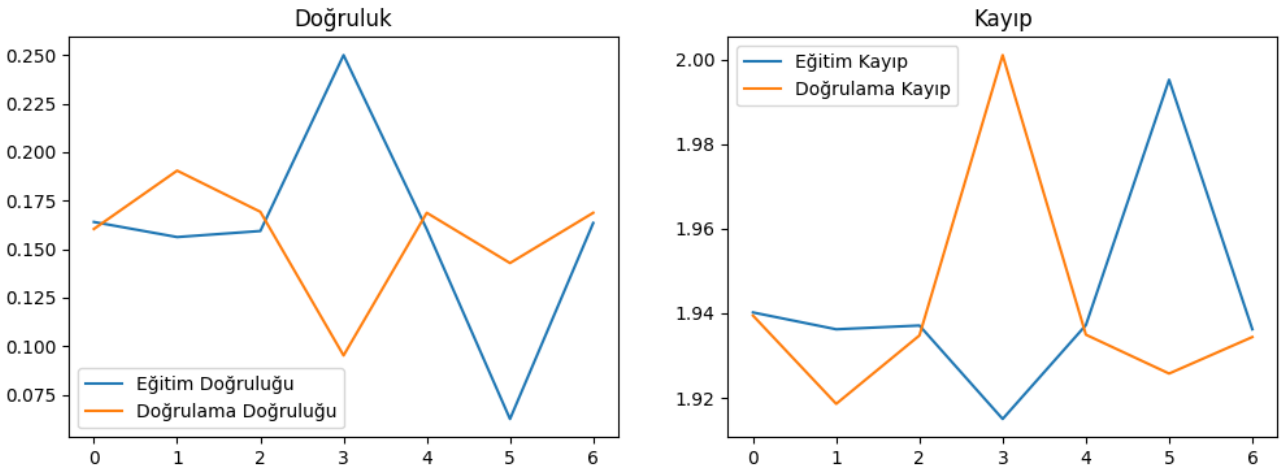

Şekil 12 – Ayarlamalar Gerçekleştirilmeden Önce

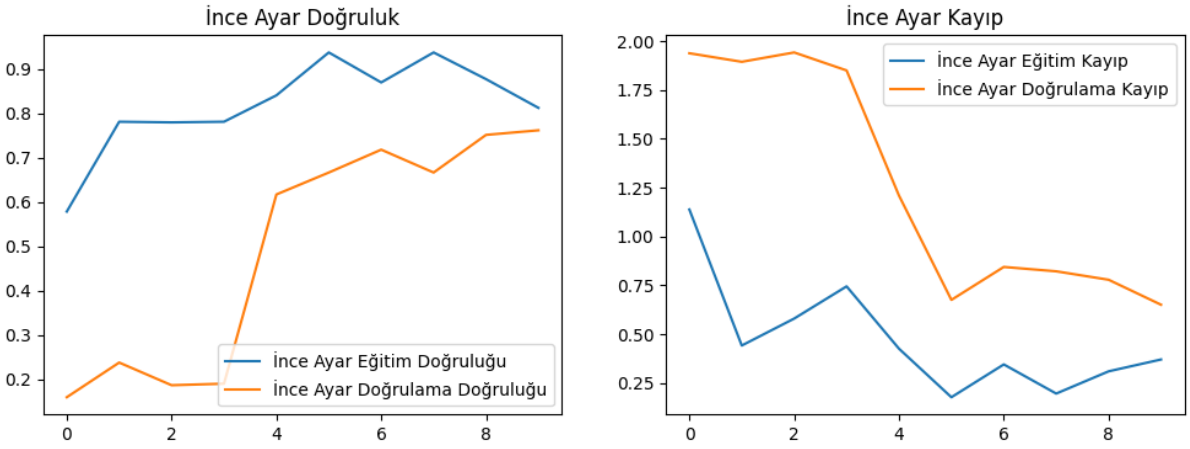

Şekil 13 – Ayarlamalar Gerçekleştirildikten Sonra

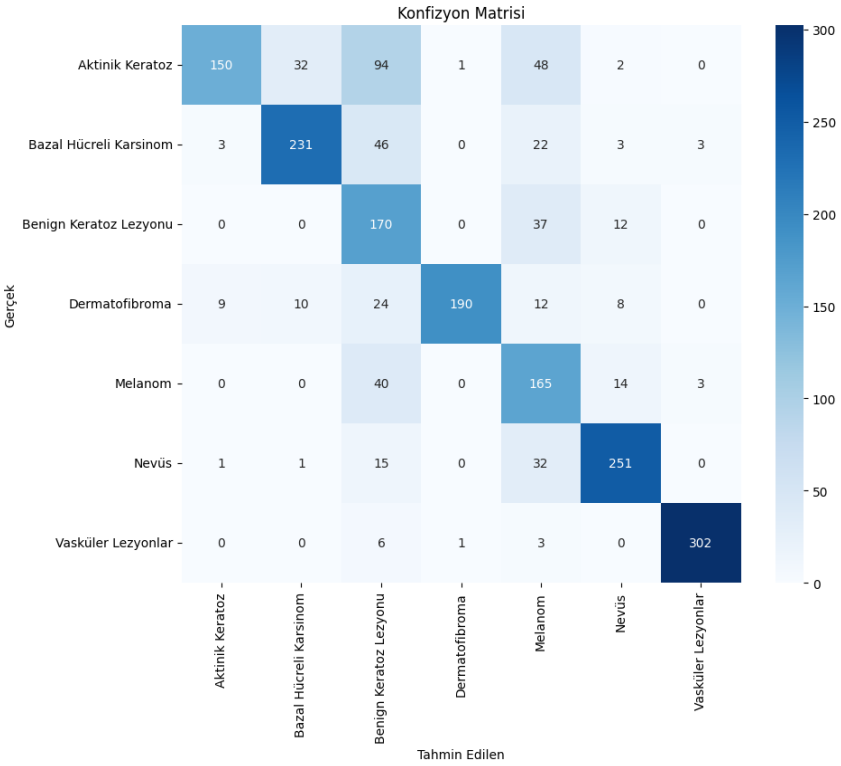

Şekil 14 – Karmaşıklık Matrisi

MobileNetV2 İle Özellik Seçimi Uygulandıktan Sonra Modelin Performansı:

Şekil 15 ve Şekil 16'te gösterilen şekillerle, ilgili özellik seçimi yöntemi uygulandıktan sonra modelin aşırı öğrendiğini söyleyebiliriz.

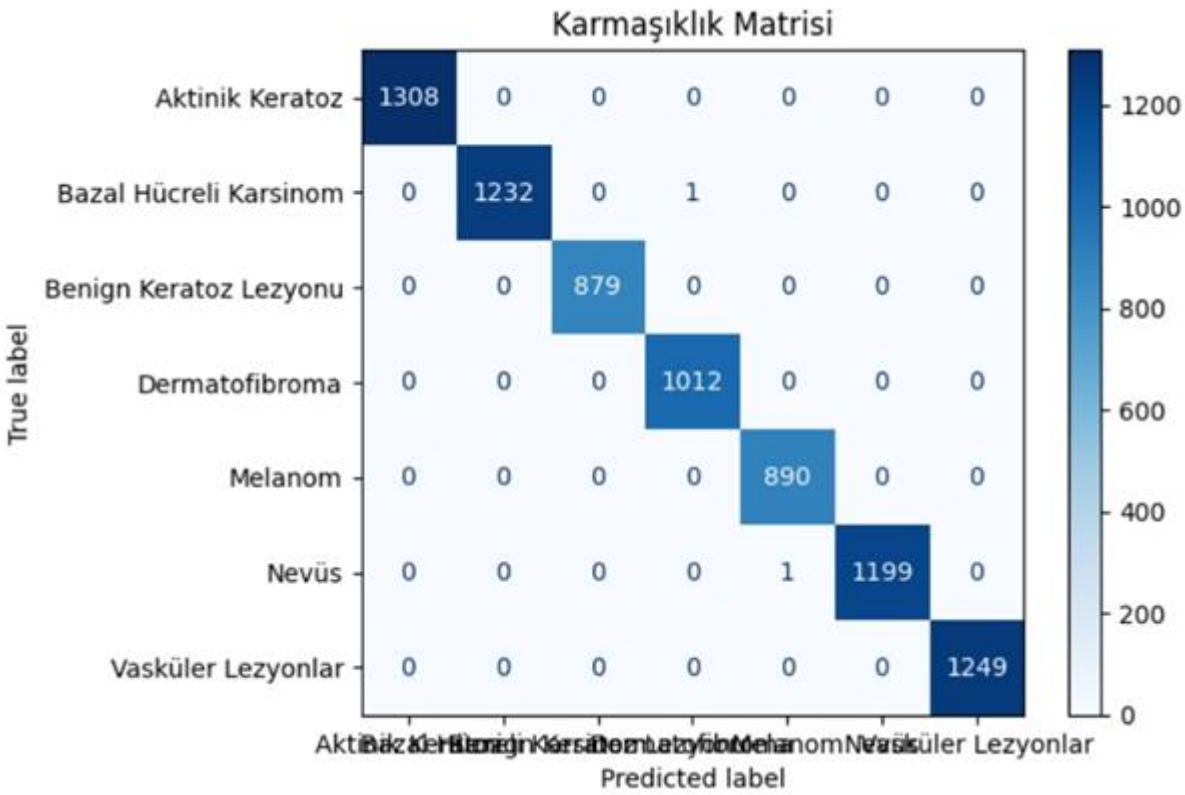

Şekil 15 – Eğitim Verileri İle Yapılan Tahminler İçin Karmaşıklık Matrisi

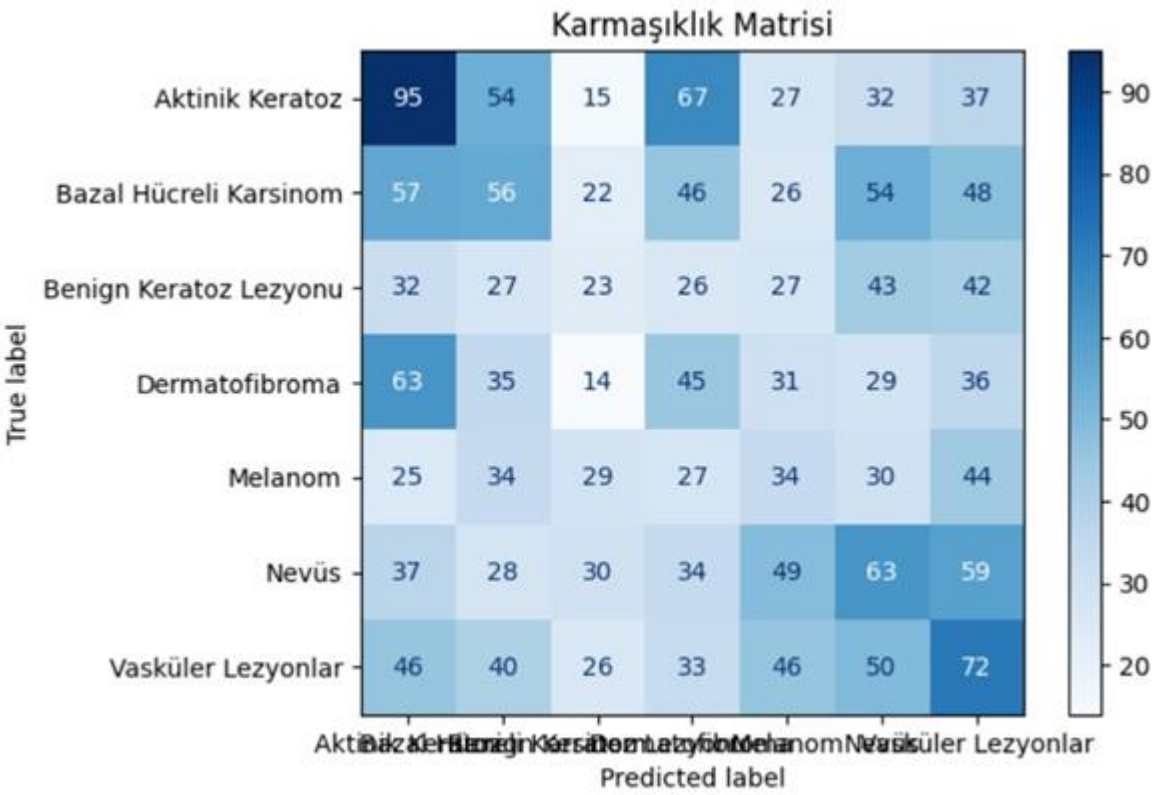

Şekil 16 – Test Verileri İle Yapılan Tahminler İçin Karmaşıklık Matrisi

Üç farklı model kullanılarak kanserli hücre tespiti için eğitimler yapılmıştır. Şekil 17 ve Şekil 18'de gösterildiği gibi yapılan eğitimin sonuçlarına göre en iyi performans alınan model MobileNet olmuştur. MobilNet'in transfer öğrenme modeli yaklaşık 10 bin görsel içeren 7 sınıflı bir veri seti üzerinden gayet kabul edilebilir bir doğruluk oranı yakalamıştır. Veri setinin dengesizliği, aşırı öğrenme ve modelin yanlış seçilmesi bu projenin en kritik noktaları olduğu kazanımı edinilmiştir. Bu problemleri çözmek için veri seti dengeleme, erken kayıp fonksiyonu döndürme ve durdurma gibi yöntemlere başvurulmuştur.

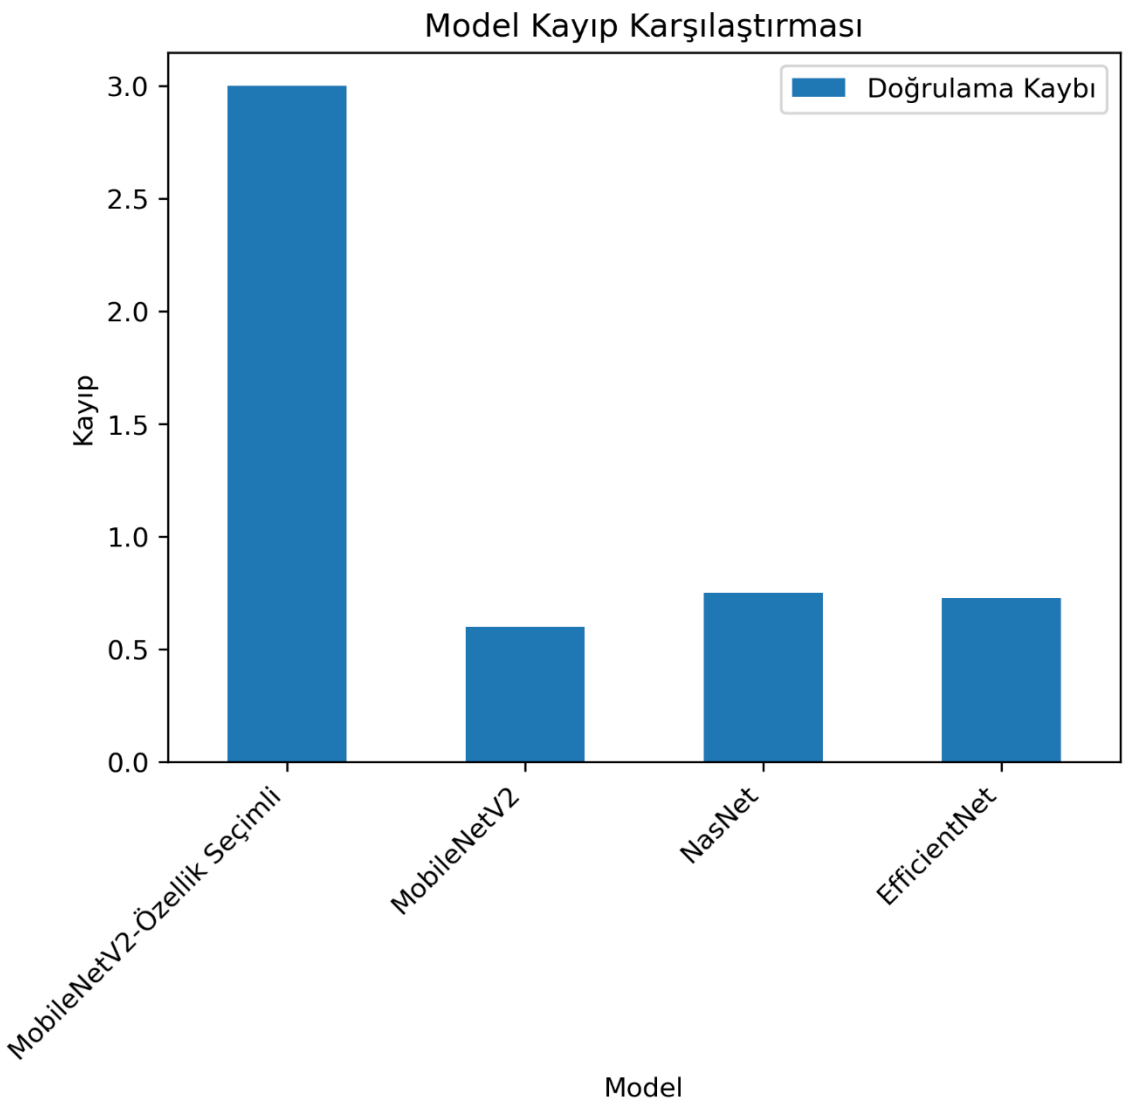

Şekil 17 – Modellerin Kayıp Karşılaştırması

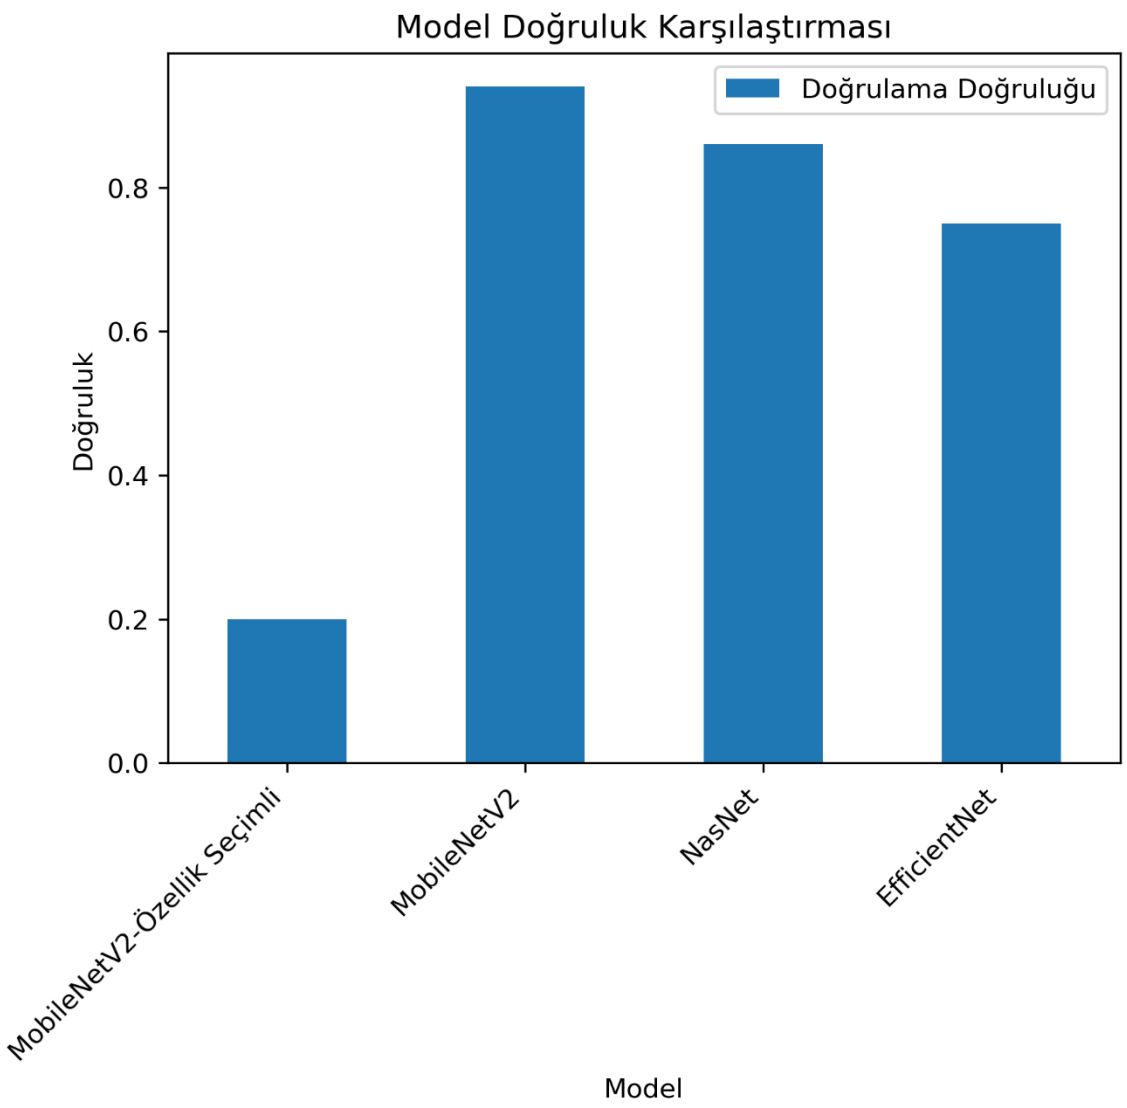

Şekil 18 – Modellerin Doğruluk Karşılaştırması

4. SONUÇ

Gerçekleştirilen çalışmalarda, etkili bir şekilde çeşitli deri kanseri tipleri için sınıflandırma işlemi gerçekleştirilmeye çalışılmıştır. 7 farklı sınıf için toplamda yaklaşık 10 bin adet görsel kullanılmış olup, eğitim ve test aşaması için oran 0.8-0.2 olarak belirlenmiştir. MobileNetV2 modelinin son konvolüsyon katmanlarından birinden özellik haritaları alınmış ve bu özellikler üzerinden seçim işlemi standart sapma ile gerçekleştirilmiştir. Model bu seçim ile birlikte aşırı öğrenme yönelimi gösterdiği saptandığından bu uygulama kullanılmadan sınıflandırma işlemi gerçekleştirilmiştir. Toplamda üç farklı model üzerinden eğitim gerçekleştirilmiş olup, **en**

yüksek başarı MobileNetV2 modelinde %94 olarak elde edilmiştir ve bu değer oldukça etkilidir. Bu çalışma, sonuç olarak elde edilen çıktılar ile ilgili sağlık kurum/kuruluşları ile iletişime geçilerek daha sağlıklı ve çeşitli veri setlerine erişim sağlanarak çalışmanın performansı önemli ölçüde artırılabilir ve sonucunda da gerçek sahada bir kullanım şansı elde edebilir.

KAYNAKÇA

[1] Y. Yuan, M. Chao, and Y.-C. Lo, “Automatic skin lesion segmentation using deep fully convolutional networks with Jaccard distance,” IEEE Trans. Med. Imag., vol. 36, no. 9, pp. 1876–1886, Sep. 2017.

[2] J. Zhang, Y. Xie, Y. Xia, and C. Shen, “Attention residual learning for skin lesion classification,” IEEE Trans. Med. Imag., vol. 38, no. 9, pp. 2092–2103, Sep. 2019.

[3] D. Patiño, J. Avendaño, and J. W. Branch, “Automatic skin lesion segmentation on dermoscopic images by the means of superpixel merging,” in Proc. MICCAI, 2018, pp. 728–736.

[4] E. Ahn et al., “Saliency-based lesion segmentation via background detection in dermoscopic images,” IEEE J. Biomed. Health Inform., vol. 21, no. 6, pp. 1685–1693, Nov. 2017.

[5] H. Ganster, P. Pinz, R. Rohrer, E. Wildling, M. Binder, and H. Kittler, “Automated melanoma recognition,” IEEE Trans. Med. Imag., vol. 20, no. 3, pp. 233–239, Mar. 2001.

[6] F. Xie, H. Fan, Y. Li, Z. Jiang, R. Meng, and A. Bovik, “Melanoma classification on dermoscopy images using a neural network ensemble model,” IEEE Trans. Med. Imag., vol. 36, no. 3, pp. 849–858, Mar. 2017.

[7] R. Amelard, J. Glaister, A. Wong, and D. A. Clausi, “High-level intuitive features (HLIFs) for intuitive skin lesion description,” IEEE Trans. Biomed. Eng., vol. 62, no. 3, pp. 820–831, Mar. 2015.

[8] K. Shimizu, H. Iyatomi, M. E. Celebi, K.-A. Norton, and M. Tanaka, “Four-class classification of skin lesions with task decomposition strategy,” IEEE Trans. Biomed. Eng., vol. 62, no. 1, pp. 274–283, Jan. 2015.

[9] A. Saez, J. Sanchez-Monedero, P. A. Gutierrez, and C. Hervas-Martinez, “Machine learning methods for binary and multiclass classification of melanoma thickness from dermoscopic images,” IEEE Trans. Med. Imag., vol. 35, no. 4, pp. 1036–1045, Apr. 2016.

[10] H. Li et al., “Dense deconvolutional network for skin lesion segmentation,” IEEE J. Biomed. Health Inform., vol. 23, no. 2, pp. 527–537, Mar. 2019.

[11] Z. Mirikharaji and G. Hamarneh, “Star shape prior in fully convolutional networks for skin lesion segmentation,” in Proc. MICCAI, 2018, pp. 737–745.

[12] J. Zhang, Y. Xie, Q. Wu, and Y. Xia, “Skin lesion classification in dermoscopy images using synergic deep learning,” in Proc. MICCAI, 2018, pp. 12–20.
[13] H. Jia et al., “3D APA-Net: 3D adversarial pyramid anisotropic convolutional network for prostate segmentation in MR images,” IEEE Trans. Med. Imag., vol. 39, no. 2, pp. 447–457, Feb. 2020.
[14] Y. Xie et al., “Knowledge-based collaborative deep learning for benignmalignant lung nodule classification on chest CT,” IEEE Trans. Med. Imag., vol. 38, no. 4, pp. 991–1004, Apr. 2019.
[15] M. M. K. Sarker et al., “SLSDeep: Skin lesion segmentation based on dilated residual and pyramid pooling networks,” in Proc. MICCAI, 2018, pp. 21–29.
[16] G. Di Leo, A. Paolillo, P. Sommella, and C. Liguori, “An improved procedure for the automatic detection of dermoscopic structures in digital elm images of skin lesions,” in Proceedings of the 2008 VECIMS. IEEE Computer Society, 2008, pp. 190–194.
[17] M. Sadeghi, M. Razmara, P. Wighton, T. K. Lee, and M. S. Atkins, “A novel method for detection of pigment network in dermoscopic images using graphs,” Computerized Medical Imaging and Graphics, vol. 35, pp. 137–143, 2011.
[18] C. Barata, J. Marques, and J. Rozeira, “Detecting the pigment network in dermoscopy images: a directional approach,” in Proceeding of the 33rd IEEE EMBS Annual International Conference, IEEE, Ed., September 2011, pp. 5120–5123.
[19] G. Fabbrocini, G. Betta, G. Di Leo, C. Liguori, and et al., “Epilluminescence image processing for melanocytic skin lesion diagnosis based on 7-point check list: a preliminary discussion on three parameters,” The Open Dermatology Journal, vol. 4, pp. 110–115, 2010.
[20] W. Stoecker, M. Wronkiewicz, R. Chowdhury, and et al., “Detection of granularity in dermoscopy images of malignant melanoma using color and texture features,” Computerized Medical Imaging and Graphics, vol. 35, pp. 144–147, 2011.
[21] W. Stoecker, K. Gupta, R. Stanley, R. Moss, and B. Shrestha, “Detection of asymmetric blotches in dermoscopy images of malignant melanomas using relative color,” Skin Research and Technology, vol. 11, pp. 179– 184, 2005.
[22] G. Di Leo, A. Paolillo, P. Sommella, and G. Fabbrocini, “Automatic diagnosis of melanoma: A software system based on the 7-point checklist,” in Proceedings of the 2010 43rd Hawaii International Conference on System Sciences, 2010, pp. 1818–1823.
[23] W. Stolz, A. Riemann, and A. B. Cognetta, “ABCD rule of dermatoscopy: a new practical method for early recognition of malignant melanoma.” European Journal Dermatology, vol. 4, pp. 521–527, 1994.
[24] M. E. Celebi, K. H., B. Uddin, H. Iyatomi, Y. Aslandogan, W. Stoecker, and R. Moss, “A methodological approach to the classification of dermoscopy images,” Computerized Medical Imaging and Graphics, vol. 31, pp. 362–373, 2007.

[25] P. Rubegni, G. Cevenini, M. Burroni, R. Perotti, G. Dell'Eva, P. Sbano, and C. Miracco, "Automated diagnosis of pigment skin lesions," International Journal of Cancer, vol. 101, pp. 576–580, 2002.
[26] H. Iyatomi, H. Oka, M. E. Celebi, M. Hashimoto, M. Hagiwara, M. Tanaka, and K. Ogawa, "An improved internet-based melanoma screening system with dermatologist-like tumor area extraction algorithm." Computerized Medical Imaging and Graphics, vol. 32, pp. 566– 579, 2008.
[27] N. Situ, X. Yuan, and G. Chen, J. Zouridakis, "Malignant melanoma detection by bag-of-features classification." in Proceedings of the 30th IEEE EMBS Annual International Conference. IEEE Computer Society, 2008, pp. 3110–3113.
[28] Y. Faziloglu, R. Stanley, R. Moss, and W. S. R. McLean, "Colour histogram analysis for melanoma discrimination in clinical images." Skin Research Technology, vol. 9, pp. 147–156, 2003.
[29] S. Seidenari, G. Pellacani, and C. Grana, "Pigment distribution in melanocytic lesion images: a digital parameter to be employed for computer-aided diagnosis." Skin Research Technology, vol. 11, pp. 236– 241, 2005.
[30] X. Yuan, Z. Yang, and G. Zouridakis, "Svm-based texture classification and application to early melanoma detection." in Proceedings of the 28th IEEE EMBS Annual International Conference, 2006, pp. 4775–4778.
[31] R. Stanley, W. Stoecker, and R. Moss, "A relative color approach to color discrimination for malignant melanoma detection in dermoscopy images." Skin Research Technology, vol. 13, pp. 67–72, 2007.
[32] M. Sheha, M. S. Mabrouk, and A. Sharawy, "Automatic detection of melanoma skin cancer using texture analysis." International Journal of Computer Applications, vol. 42, pp. 22–26, 2012

Görseller:[1] https://www.geeksforgeeks.org/what-is-mobilenet-v2/